

Gyeongmin Kim (김경민)

TTS · ASR · VC · SE · LLM 모델을 데이터 구축부터 모델 최적화 · 추론 가속, 서빙까지 직접 다룹니다.

kdrkdrkdr@hanyang.ac.kr · (+82) 10-3323-0349 · github.com/kdrkdrkdr · linkedin.com/in/kdrkdrkdr · 병역: 산업기능요원 편입 희망

Publications

Preprints

faster-enhancer.c: A Dependency-Free int8 Runtime for Streaming Speech Enhancement on Commodity CPUs

Gyeongmin Kim. arXiv:2607.25350, 2026.07. [[arXiv](#)] [[code](#)]

Extracting Voice Styles from Frozen TTS Models via Gradient-Based Inverse Optimization

Gyeongmin Kim. arXiv:2607.25351, 2026.07. [[arXiv](#)] [[code](#)]

Under review

Why One Small Fixed Tree Suffices: The Cost Geometry of Draft Trees for a Multi-Token-Prediction Drafter

Gyeongmin Kim, Ayoung Moon, Seung Jin Lee. Under review, 2026.

Experience

NC AI (KR)

2026년 5월 ~ 현재

소속: AI데이터실 데이터엔지니어링팀 (팀원)

■ [콘텐츠진흥원 과제] 문화 콘텐츠 추천 대화 시스템 설계 및 VAETKI 양자화·서빙

외국인·문화 소외계층에게 한국 문화 콘텐츠를 추천하는 대화 시스템의 LLM 파이프라인을 설계·구현하고, VAETKI-120B-A10B의 양자화와 서빙을 담당했습니다. (프로젝트 인원: 6명 · 역할: 시스템 설계·개발, 모델 양자화, 서빙)

- **이원 경로 설계** — 긴 프롬프트에서 지시 이행이 무너지는 모델 한계를 경로 분리로 우회 — 일반 대화와 추천(전용 프롬프트 + RAG API 연동) 요청을 별도 VAETKI 호출로 나눠 경로당 프롬프트를 최소화
- **컨트롤러** — Qwen3.5-4B가 실시간 대화에서 페르소나(취향·호불호)를 추출하고 사용자의 한국어 수준(상/하)을 분류해 VAETKI 응답에 반영, 대화 맥락으로 추천 시점을 판단해 추천 경로로 전환
- **통합 서버** — 전체 흐름을 FastAPI 서버로 구현, 응답을 문장 단위로 분할해 TTS API로 비동기 스트리밍 전달
- **양자화** — attention · FFN · MoE expert의 전 Linear를 INT8로 내리고, 손실 민감 지점(lm_head · router gate · RMSNorm · embedding)은 BF16 가중치로 유지(추론 시 fp32 연산) — **상대 L2 오차 0.093%** · **코사인 유사도 0.99961** · **SNR 40.9dB**
- **서빙** — 양자화 모델을 vLLM으로 서빙, Demo 페이지 구축

키워드: Python, LLM, RAG, Quantization, W8A16, INT8, MoE, vLLM, FastAPI, Streaming, Model-Serving, Inference-Optimization

■ [데이터 생성 파이프라인] 구축 및 추론 가속

대량의 데이터를 생성하는 파이프라인을 구축하고, 추론 처리량 병목을 **노드당 처리량**과 **노드 간 분산** 두 축으로 해결했습니다. (프로젝트 인원: 3명 · 역할: 추론 최적화 · 연구 리드 — 결과 논문 투고)

- **노드당** — Gemma4-31B용 multi-token-prediction assistant 모델을 drafter로 활용해 speculative decoding을 사내 파이프라인에 도입, vLLM · A100 x4 환경에서 **AR 대비 2~4x** 가속으로 운영 중
- **노드 간** — 구성원들이 각자 띄운 vLLM 서버는 중계 계층이 없어 매번 IP·포트로 수동 라우팅해야 했고, 자동 분산 게이트웨이를 제안·구현해 GPU 4장 서버 8대(총 32 GPU)를 주소 등록만으로 단일 엔드포인트에 통합
 - 게이트웨이 자체가 병목이 되지 않도록 Go로 구현 — **동시 요청 1,000건 기준 라우팅 지연 평균 15ms**. OpenAI API 호환 인터페이스로 기존 클라이언트 코드 수정 없이 전환, 현재 사내 운영 중

키워드: Python, Go, LLM, Speculative-Decoding, vLLM, API-Gateway, Load-Balancing, Concurrency, OpenAI-Compatible-API, Data-Generation, Inference-Optimization

■ [NGS 기반 임상리포트 자동생성 파일럿 사업 (국책과제)] 개발 리드

엑셀 파일의 검사결과를 NGS 결과지 템플릿에 수작업으로 옮기는 과정에서 휴먼 에러 가능성이 커, 이를 자동화하는 웹 기반 리포트 생성 도구를 개발했습니다. (프로젝트 인원: 3명 (의생명시스템정보학교실/병리과) · 역할: 개발, QA) [code]

- 엑셀 파일 업로드 시 Web PDF로 자동 변환·저장하는 기능 추가
- 각 컴포넌트의 요소, 유전체 검사 결과 값 및 위치, 코멘트 수정 기능 추가
- SQLite+Json+Javascript로 데이터 파싱 및 페이지 분할 기능 구현

키워드: Python, FastAPI, Medical-Data-Processing, Html/CSS/Javascript

■ [SICU False Alarm Monitoring System] 개발 리드

외과계 중환자실의 잦은 알람(가짜 알람 포함)으로 간호사들이 극심한 스트레스를 받고 있어, 알람의 진위를 판별해 줄이려는 연구에 쓰일 데이터 뷰어 프로그램을 개발했습니다. (프로젝트 인원: 5명 (의생명시스템정보학교실/마취통증의학과) · 역할: 개발, QA) [code]

- 입원 시간별 날짜 선택(입원기간/날짜)
- 환자 위태 심각도에 따른 색깔별 알람 선택 기능
- 간호 기록 엑셀화 및 필터링 기능 (전후 30분 간호중재/간호활동/간호속성코드/속성/Duty/시행일시)
- 알람 울린 시간대의 환자 파형 뷰 (ABP/Lead-II/Resp/Pleth)
- 알람 진위 판정, 코멘트 작성·저장 기능

키워드: Python, Medical-Data-Processing, PySide6, SQLite

엔씨소프트 (KR)

2024년 7월 ~ 2025년 1월

소속: AI데이터실 오디오데이터팀 (팀원)

■ [AUDT_자동화 프로젝트] 오디오 후처리 자동화 프로그램 개발

상업용 오디오 처리 프로그램이 원본 파형을 손상시켜 팀원들이 데이터를 수작업으로 처리하고 있어, 품질을 유지하며 후처리를 자동화하는 프로그램을 개발했습니다. (프로젝트 인원: 5명 · 역할: 개발, QA)

- 녹음실 미세소음 제거: 녹음된 성우의 음성 파일에서 녹음실의 미세한 잡음을 남김없이 제거
- 숨소리 제거: F0 미검출 특성과 보정값을 이용하여 음성에서 숨소리를 제거
- Endpoint Detection: TTS 학습을 위해 맨 앞과 뒷부분을 감지하여 공백을 일정하게 삽입
- 텍스트 태깅: 대만어 데이터의 간체자 혼입을 태깅하여 대사 수정을 빠르게 할 수 있도록 구현
- 문장 부호 공백 삽입: CTC forced aligner로 오디오-텍스트를 단어 단위 정렬해, 문장 부호 종류별로 다른 길이의 공백을 삽입

키워드: Text-to-Speech, Data Processing Automation, CTC Forced-Alignment, PyTorch, GUI, Numpy

Taiyaki Studios Ltd. (US)

2023년 1월 ~ 7월

소속: Artificial Intelligence (팀원)

■ [사내용 TTS 학습 도구 개발]

사내 구성원의 목소리로 TTS를 만들려 했으나 음성 데이터가 적고 파이프라인도 없어, 적은 데이터로도 학습 가능한 TTS 학습 도구를 개발했습니다. (프로젝트 인원: 2명 · 역할: 개발, QA)

- 데이터셋 구축: 긴 음성 파일을 TTS 학습에 적합하게 분할하고 대사 파일을 자동 생성. 음성 변환 및 증강 기법으로 데이터 부족 문제 해결
- 모델 학습: TTS 모델과 G2P 코드를 개발하고, 사전 학습 모델 기반으로 적은 데이터로도 미세 조정이 가능하도록 구현. 모델 압축을 통해 저장 효율성 향상
- 성능 테스트: RTF로 추론 속도를, MOS로 발음 정확성을 측정. 하이퍼파라미터 조정으로 모델을 경량화하여 빠른 추론 속도 달성
- 파이프라인 구축: TTS 모델을 실제 서비스에 배포하기 위한 추론 코드를 작성하여 파이프라인 구축

키워드: Python, Text-to-Speech, Few-shot, Voice-Conversion, Deep-Learning

Personal Projects

■ 모델 최적화 (2024.11 ~ 현재)

PyTorch/ONNX 의존성 없이 음성 모델을 순수 C로 재구현하고 최적화하여, GPU/NPU 없이 CPU만으로 실시간 동작하게 만들었습니다.

- **memotron-asr-streaming.c** — 0.6B 스트리밍 ASR (FastConformer + RNN-T) [구현 문서] [양자화 모델]
 - cache-aware 스트리밍 상태 유지, chunk 지연 5단계(80~1120ms, 기본 320ms) 선택
 - W8A8 양자화 — per-row int8 + 32-bit row scale를 4-row 타일로 packing(“Q8P”), 가중치 0.62GiB
 - NEON/AVX2 SIMD 자동 디스패치, 최대 16 스레드 병렬화
- **LILAC** — 3초 레퍼런스만으로 동작하는 zero-shot 실시간 음성 변환 (OpenVoice v2 포팅) [최적화 리스트]
 - 스트리밍 HiFi-GAN 디코더 — per-layer state 유지로 hop당 신규 프레임만 생성
 - 2-thread SPSC ring 오디오 파이프라인, 3-way 병렬 resblock dispatch, RNNoise SIMD(AVX2) 통합
 - AGC + VAD hangover gate. 16-core CPU에서 RTF 0.7~0.8, end-to-end 270~330ms
- **MossTTS-Nano.c** — 100M TTS 모델 [최적화 리스트]
 - NEON/AVX SIMD · KV cache · pthread 병렬화 등 12단계 최적화로 합성 68s → 2.3s
 - PyTorch CPU 대비 1.8배 빠른 RTF 0.33
- **DeepFilterNet3.c.wasm** — 노이즈 제거 모델의 순수 C 재작성 + WASM 빌드 [최적화 리스트]
 - 기존 WASM 빌드가 모바일에서 실시간 처리가 안 되던 것을 브라우저에서 동작하도록 최적화 — 프레임당 MacBook M2 ~1ms · Galaxy S23 ~4ms

키워드: C, WebAssembly, SIMD, OpenBLAS, Quantization, Streaming-ASR, Voice-Conversion, Noise-Reduction, Real-time-Audio-Processing, Python

■ Axcellworks (JP) 실시간 음성 변환 명료도 개선 — 원격 기술 협업 (2023.11 ~ 2024.02)

일본 스타트업 Axcellworks와 원격으로 협업해, 실시간 음성 변환에서 청크 단위로 추론할 때 경계마다 목소리가 끊기고 명료도가 떨어지는 문제를 개선했습니다.

- 청크 경계에서 모델의 receptive field가 잘려 컨텍스트가 부족해지는 것이 원인 — 좌우 이웃 청크를 컨텍스트로 덧대 추론하고 가운데 청크만 취하는 **overlap-save 방식**으로 경계 아티팩트를 제거, 기존 대비 지연 증가 없이 변환 음성의 명료도 개선

키워드: Realtime-Voice-Conversion, Python

■ 다국어 음성 합성 (2022.10 ~ 2025.02)

학습 데이터가 부족한 조건에서 VITS를 파생시켜 언어와 화자를 늘리고, 캐릭터 TTS 서비스로 배포했습니다.

- **모델** — VITS 파생 3종
 - 일본어 데이터셋만으로 19개국어 발화 유도 (**JA2ML-VITS**)
 - 한국어/일본어 이중 언어 (**JK-VITS**)
 - RVC로 음성 데이터셋을 변환해 학습 데이터 확보 (**RVC-VITS**)
- **G2P** — pyopenjtalk 내부 API 수정 + g2pk3 + hangulize를 조합한 음소 변환 체인으로 JA2ML-VITS의 다국어 발화를 구현, 자작 패키지 2종은 PyPI로 공개
 - **g2pk3** — 한국어/일본어/영어를 한국 발음으로 표기 [**PyPI**]
 - **ko2kana** — 한국어/영어 발음을 가타카나로 변환 [**PyPI**]
- **서비스** — HuggingFace Space 2종
 - 학습 데이터 — BGM 제거(Kim Vocal) → 화자 분리(pyannote) → VAD 분할 → 전사(Whisper)로 3~10초 클립 약 3만 개 구축
 - **ProsekaTTS** — 2026년 07월 기준 누적 방문 230만 · 개발자 복제(Duplicate) 60회
 - **ShirokoTTS** — 영어/한국어/일본어 3개국어 지원

키워드: Python, Text-to-Speech, Fine-Tuning, Grapheme-to-Phoneme(G2P), Phoneme-Conversion, Voice-Conversion, Source-Separation, Speaker-Diarization, Whisper, Data-Augmentation, Selenium, Distributed-Crawling

■ 일본어 번역 도구 (2020.12 ~ 2022.04)

일본어 콘텐츠를 한국어로 번역하는 다양한 도구를 개발했습니다.

- **novel-reader** — 소설가가되자, 카쿠요무 등 7개 사이트의 소설을 다국어로 번역하는 안드로이드 앱. 고유명사 사전 등록 시스템 탑재
- **EhndWebTranslate** — 일본어 웹사이트를 비동기 번역하여 표시. 문서/소설/실시간 번역 지원
- **UserDict4Papago** — Papago 한일 번역의 고유명사 문제를 사전 등록으로 개선

키워드: Android, Java, Python, Machine-Translation, PySide2, Flask, Selenium

Extracurricular Activities

엘니노 (KR)

2024년 4월 ~ 2026년 4월

역할: 대표 (개발, QA, 서류 작성 · 2인 팀) · 창업동아리 시작(2024.04) → 개인사업자 등록(2025.02) → 운영 종료

■ [Knoc] 실시간 번역 자막 서비스

문맥과 분야를 인식해 정확하고 빠르게 번역하는 수업 · 컨퍼런스용(온/오프라인) 통역기를 개발했습니다.

- Python 기반 초기 서비스를 대규모 웹소켓 처리를 위해 Go로 전면 재작성
- Redis Pub/Sub 기반 실시간 번역 방 및 스크린 송출 시스템 구축
- 분산 컴퓨팅 아키텍처 설계 및 구현
- 웹 클라이언트 개발: 유튜브형/컨퍼런스형 자막 모드, Context & Field-Based Any-to-Any Translation Model 적용
- 사용자 대시보드 개발: 사용시간/통역시간 관리, PAYG 및 구독제 결제 · 플랜 · 영수증 관리, 팀 멤버 관리, 사용 기록 조회
- 관리자 대시보드 개발: 팀 정보 관리, 견적서 입력, 서버 리소스 관리 및 로그 모니터링, 팀별 플랜 생성 · 결제 관리, 팀 통역시간 실시간 모니터링

키워드: Go, Speech-to-Text, LLM, Prompt-Engineering, Redis, PostgreSQL, NginX, WebSocket, Distributed-Computing, Html/CSS/Javascript

■ [Knoc-Overlay] 데스크톱 자막 오버레이 애플리케이션

Knoc 실시간 번역 자막을 데스크톱 화면 위에 오버레이로 표시하는 Electron 기반 애플리케이션을 개발했습니다.

키워드: Electron, Javascript, Html/CSS

■ elnino.kr 회사 웹사이트 개발

엘니노 공식 웹사이트를 직접 디자인 및 개발했습니다.

키워드: Html/CSS/Javascript

■ 관련 활동

- Multilingual.com 해외 언론 보도 (2026.04)
- 실시간 번역 자막 서비스 Knoc 정식 출시 (2026.03)
- 건국대학교 윈터스쿨 번역 자막 서비스 제공 (2026.02)
- 대한영상의학기술학회 실시간 번역 자막 서비스 제공 (2025.03)
- 엘니노 창업 (2025.02)
- 교육부 U300+ 학생 창업 유망팀 성장트랙 최종 선발 (2024.08)
- 한양대학교 청년 창업아이템 챌린지 경진대회 본선 발표 (2024.06)
- 한양대학교 창업동아리 경진대회 본선 발표 (2024.06)
- Naver D2SF 서류합격 (2024.05)
- 한양대학교 창업동아리 엘니노 대표 (2024.04)

License & Education

License

- 프로그래밍기능사 (구 정보처리기능사) (2026.07.03)
- 운전면허 2종 (2023.07.31)
- ITQ A등급 (2016.12.15)

Education

- 한양대학교 공과대학 컴퓨터소프트웨어학부
재학: 2023.03 ~ 2024.06, 휴학: 2024.07 ~